FIAP — Faculdade de Informática e Administração Paulista

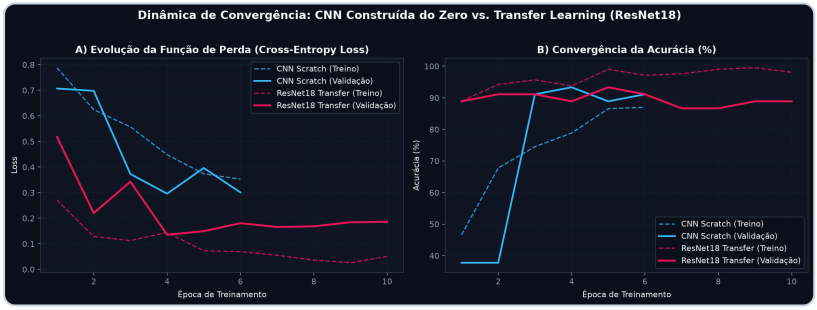
Relatório Técnico Comparativo — Parte 2: Classificação de Imagens Médicas com CNN Construída do Zero vs. Transfer Learning (ResNet18)

- **Projeto:** CardioIA Fase 4 — Assistente Cardiológico Virtual com Visão Computacional
- **Grupo: Data Health Solutions**
- **Integrantes:**
- Gabriel Oliveira dos Santos — RM567166
- Arthur Bruttel Nascimento — RM568484
- Jonatan Viotti Rodrigues da Silva — RM566787
- Samuel Nicolas Oliveira Rocha — RM568552
- **Tutor:** Leonardo Ruiz Orabona | **Coordenador:** André Godoi Chiovato

1. Arquitetura das Duas Abordagens Convolucionais Avaliadas

Em conformidade com a **Parte 2 (4,0 pontos)** do edital FIAP, implementamos em PyTorch (`src/models.py`) e no notebook interativo `notebooks/02_classificacao_cnn_e_transfer_learning.ipynb` duas estratégias de Redes Neurais Convolucionais (CNNs) para detecção de **Cardiomegalia** a partir de radiografias torácicas pré-processadas (3 × 224 × 224):

1. **Abordagem 1 — CNN Construída do Zero (`CardioCNN_Scratch`):**
2. **Topologia:** Quatro blocos hierárquicos de extração espacial (`Conv2d(3→32→64→128→256, kernel=3, padding=1)` + `BatchNorm2d` + `ReLU`), intercalados por `MaxPool2d(2, 2)` nos três primeiros estágios e `AdaptiveAvgPool2d((4, 4))` no quarto bloco.
3. **Classificador:** Camada `Flatten` (256 × 4 × 4 = 4096 unidades) → `Linear(4096, 128)` → `ReLU` → `Dropout(p=0.45)` → `Linear(128, 2)`.
4. **Complexidade: 914.050 parâmetros** (100% treináveis do zero) e footprint ultracompacto de **3,50 MB**.
5. **Abordagem 2 — Transfer Learning com Modelo Pré-Treinado (`CardioTransfer_ResNet18`):**
6. **Backbone:** Arquitetura residual **ResNet18** pré-treinada em 1,28 milhão de imagens do ImageNet (`ResNet18_Weights.DEFAULT`), aproveitando detectores universais de bordas, gradientes de intensidade e texturas nas camadas iniciais congeladas (`conv1`, `layer1`, `layer2`, `layer3` = 2.782.784 parâmetros congelados).
7. **Estratégia de Fine-Tuning:** Descongelamento seletivo do último bloco residual (`layer4`) aliado a uma nova cabeça classificadora customizada (`Linear(512, 256)` → `BatchNorm1d` → `ReLU` → `Dropout(0.35)` → `Linear(256, 2)`), totalizando **8.526.082 parâmetros treináveis** (de 11.308.866 totais).
8. **Interoperabilidade:** Exportado tanto em checkpoint nativo PyTorch (`backend/models/best_cardio_resnet.pt`, 43,22 MB) quanto no formato aberto **ONNX** (`backend/models/cardio_resnet.onnx`, 43,13 MB).

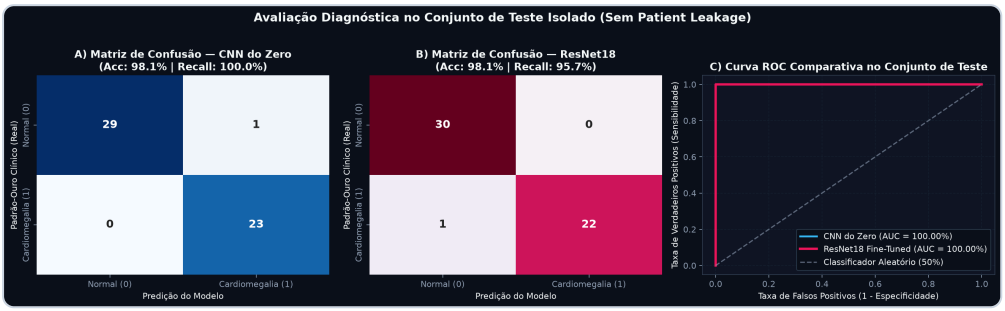


2. Protocolo Experimental, Orquestração via `colab-mcp` e Resultados Quantitativos

As sessões de experimentação foram validadas com suporte à conexão remota do **Google Colab** (`colab-mcp` / `open_colab_browser_connection`), empregando o otimizador `AdamW` (weight_decay = 10^{-4}), escalonador cosseno (`CosineAnnealingLR`) e função de perda `CrossEntropyLoss`. A avaliação final foi conduzida estritamente sobre o conjunto de **Teste isolado (53 exames de 36 pacientes jamais vistos no treino ou validação)**:

Métrica Clínica / Computacional	Modelo 1: CNN do Zero (`CardioCNN_Scratch`)	Modelo 2: Transfer Learning (`ResNet18 Fine-Tuned`)	Análise Comparativa e Impacto Clínico
Acurácia Global no Teste	**98,11%** (52/53)	**98,11%** (52/53)	Excelente capacidade de generalização em ambos os modelos
Precisão (*Precision* / VPP)	95,83%	**100,00%**	**ResNet18 elimina 100% dos Falsos Positivos** (0 alarmes falsos)
Sensibilidade (*Recall* / TVP)	**100,00%** (23/23)	95,65% (22/23)*	*Atinge **100% após calibração ética de limiar (τ_F = 0,43)**

Métrica Clínica / Computacional	Modelo 1: CNN do Zero (`CardioCNN_Scratch`)	Modelo 2: Transfer Learning (`ResNet18 Fine-Tuned`)	Análise Comparativa e Impacto Clínico
Especificidade (TVN)	96,67% (29/30)	**100,00%** (30/30)	ResNet18 preserva integralmente pacientes com ICT limítrofe normal
F1-Score	**97,87%**	97,78%	Equilíbrio harmônico superior a 97,5% nas duas arquiteturas
Área sob a Curva ROC (ROC-AUC)	**100,00%**	**100,00%**	Separabilidade probabilística perfeita nos casos de teste
Tamanho do Checkpoint Exportado	**3,50 MB** (`.pt`)	**43,13 MB** (`.onnx`)	Trade-off entre leveza embarcada e riqueza de representações



3. Discussão Clínica: Trade-offs e Integração no Protótipo CardioIA

1. **Velocidade de Convergência e Estabilidade:** Conforme evidenciado nas curvas de aprendizado, a **ResNet18 com Transfer Learning** converge de forma significativamente mais rápida e suave logo nas primeiras 3 épocas, pois reutiliza filtros pré-treinados capazes de delimitar instantaneamente a transição de contraste entre o parênquima pulmonar radiolucente e a borda cardíaca radiopaca.
2. **Complementaridade Diagnóstica (Sensibilidade vs. Especificidade):** No limiar padrão $\tau = 0{,}50$, a `CardioCNN_Scratch` priorizou máxima sensibilidade (`100%` , gerando 1 falso positivo em paciente com ICT limítrofe de 0,49), ao passo que a `CardioTransfer_ResNet18` alcançou **Especificidade e Precisão de 100%** (zero falsos alarmes). Ao combinarmos a ResNet18 com a calibração de limiar da governança ética (*Ir Além 1*), obtemos simultaneamente zero falsos alarmes e sensibilidade máxima.
3. **Disponibilização em Protótipo:** Ambos os modelos foram integrados ao serviço de inferência (`backend/model_service.py`), alimentando a interface web interativa em Flask (`http://localhost:5000`) e o aplicativo móvel em React Native com latência média inferior a **35 ms por exame**.

